

Sommario

- Introduzione
- Panorama sui provider di Al
- Introduzione a GPT
- Creazione della API Key e funzioni principali
- Utilizzo di request con python
- Esempi di chiamata

Panorama sui diversi provider di Al

Fornitore	Modelli Principali	Tipo di API	Costo	Supporto Fine-Tuning	Esempi di Uso
OpenAl	GPT-4, GPT-3.5, DALL·E	REST API	A consumo	Sì (per alcuni modelli)	Chatbot, Generazione immagini, Codice
Anthropic	Claude 3	REST API	A consumo	No	Assistenza Al, Analisi testi
Google Al	Gemini 1.5	REST API	A consumo	Sì	Ricerca, Generazione contenuti, Cloud Al
Meta Al	LLaMA 3	ollama	Gratuito	Sì	Ricerca, Al on-device, Conversazionali
Hugging Face	Vari modelli open-source	Hub API	Gratuito/A consumo	Sì	Deployment AI, Fine-tuning, Hosting modelli
Microsoft	GPT-4 (Azure OpenAl)	REST API (Azure)	A consumo	Sì	Integrazione aziendale, Al per produttività

Introduzione alle API

Le **API REST** di ChatGPT permettono di integrare l'intelligenza artificiale di OpenAl nelle proprie applicazioni.

Creazione della API Key

Per utilizzare le API, è necessario prima ottenere una API Key che servirà a monitorare il raggiungimento dei limiti. Di seguito la procedura per crearne una:

- 1. Accedi al sito OpenAl.
- 2. Vai alla sezione "API Keys".
- 3. Crea una nuova chiave API e salvala in un posto sicuro.

Come richiamare le API

Per richiamare delle **API REST** python mette a disposizione la libreria request, che consente di gestire in maniera semplice le chiamate ai vari metodi **HTTP**.

Librerie dei provider

Ogni provider fornisce le proprie libreri per richiamare le API,nascondendo i dettagli della chiamata e semplificandone dunque l'utilizzo:

- openai: openai
- Microsoft: Azure SDK per Python
- **Google**: SDK Google Gen Al (Gemini)
- **AWS**: AWS SDK for Python (Boto3)

NOTA: Per rimanere il più possibile VENDOR-FREE è meglio scegliere la chiamata diretta tramite request.

Endpoint Principali di **OPENAI**

Di seguito gli endpoint principali delle API:

Metodo	Endpoint	Descrizione
POST	/v1/chat/completions	Ottenere risposte in linguaggio naturale
POST	/v1/images	genera immagini da una descrizione testuale
POST	/v1/audio	Funzioni TTS (Text to Speech) e STT (Speech to Text)
POST	/v1/embeddings	Generare embedding vettoriali da un testo,

NOTE: La documentazione completa delle API si può trovare sul sito ufficiale nella sezione apireference

Endpoint Principali

/v1/chat/completions

Questa API permette di interagire con ChatGPT per ottenere risposte in linguaggio naturale.

Impostazione delle chiamata alle api

```
import requests

# IMPOSTAZIONE DELL'ENDPOINT
url = "https://api.openai.com/v1/chat/completions"

# IMPOSTAZIONE DELL'HEADER con API KEY
headers = {"Authorization": "Bearer <API KEY>", "Content-Type":
"application/json"}
```

Endpoint Principali

/v1/chat/completions

Impostazione del body

```
# IMPOSTAZIONE DELL'ENDPOINT ...
# IMPOSTAZIONE DELL'HEADER con API KEY ...
# IMPOSTAZIONE DEL BODY DELLA RICHIESTA

data = {
    "model": "gpt-4o-mini",
    "messages": [
          {"role": "system", "content": "Sei un assistente utile."},
          {"role": "user", "content": "Ciao, come stai?"}
    ], "temperature": 0.7
}
```

Endpoint Principali

/v1/chat/completions

Chiamata effettiva

```
# IMPOSTAZIONE DELL'ENDPOINT ...
# IMPOSTAZIONE DELL'HEADER con API KEY ...
# IMPOSTAZIONE DEL BODY DELLA RICHIESTA ...
# CHIAMATA EFFETTIVA
response = requests.post(url, headers=headers, json=data)
print(response.json()["choices"][0]["message"]["content"])
```

Endpoint Principali

/v1/chat/completions

Struttura della risposta

```
"model": "string",
"choices": [
    "index": ∅,
    "message": {
      "role": "assistant",
      "content": "string"
    },"finish_reason": "string"
```

Endpoint Principali

/v1/chat/completions

l'oggetto choices

Attributo	Tipo	Descrizione
index	integer	Indica la posizione della risposta nella lista choices. Parte da 0.
message	object	Contiene il messaggio generato dal modello.
message.role	string	Indica il ruolo del messaggio ("assistant").
message.content	string	Contiene il testo della risposta generata dal modello.
finish_reason	string	Indica il motivo per cui la generazione si è fermata.

Endpoint Principali

/v1/chat/completions

Possibili valori di finish_reason

Valore	Descrizione
stop	La risposta è stata generata completamente.
length	Il modello ha raggiunto il limite massimo di token disponibili.
content_filter	Il contenuto generato è stato filtrato per motivi di sicurezza.
function_call	Il modello ha restituito un'azione da eseguire invece di un testo normale.

Modelli e limiti di GPT

Modello	Capacità	Limiti Gratuiti	Differenze rispetto ai modell precedenti
GPT-3.5	Buona comprensione e generazione testuale	Accesso limitato e meno richieste al minuto	Più veloce di GPT-4, ma meno preciso
GPT-4o- mini	Prestazioni avanzate e maggiore accuratezza	Limitazioni nell'accesso gratuito	Più creativo e affidabile rispetto a GPT-3.5
GPT-4 Turbo	Versione ottimizzata di GPT- 4	Disponibile per utenti a pagamento	Maggiore velocità ed efficienza
DALL-E 2	Generazione di immagini basata su testo	Uso limitato nel piano gratuito	Migliore qualità rispetto alle versioni precedenti

Nota: L'accesso ai modelli più avanzati (es. GPT-4 e Turbo) potrebbe essere limitato a seconda del pian di utilizzo selezionato.

Domande





- 1. Creare un programma che fornita una domanda chiami le api di completitions per ottenere una risposta.
- 2. Creare un programma che a fronte di un testo e di una domanda fornisca il testo e la domanda alle api di completitions per ottenere una risposta contestualizzata.
- 3. Creare un programma che a fronte di un pdf e di una domanda, fornisce una risposta chiamando le API di completitions.